PRÁCTICA 2: BASE DE DATOS, BALANCEO Y ESCALADO

RAÚL MATEUS SÁNCHEZ

COMPUTACIÓN EN LA NUBE Escuela de Ingeniería Informática

Índice

Introducción	2
Objetivos	2
Desarrollo de la práctica	3
1. Despliega dos instancias en EC2 con un servidor web que muestre una página sir pero que se pueda reconocer que es un servidor distinto. E.g. [El servidor de Gabriel 2 servidor de Gabriel 2]. Estos servidores deben poder ser accedidos con un naveador desde fuera	1] [El
2. Despliega un "load balancer" que distribuya las peticiones entre los dos servidor partes iguales	
3. Prepara un "template" de instancia para EC2 para generar servidores web. Con e "template" declarar un "Auto-Scaling Group"(ASG) que tenga como mínimo una insta y como máximo 2. El ASG debe añadirse al "load balancer" previamente desplegado. Comprueba que el ASG mantiene al menos una instancia viva y que el "load balancer manda peticiones entrantes	ancia " le
Diagrama de arquitectura desplegada	20
Presupuesto y estimación de gasto de los recursos desplegados	21
Conclusiones	22

Introducción

Dentro de Amazon Web Services, las posibilidades son infinitas. Por ello, deben ser exploradas y analizadas para saber su utilidad dependiendo del coste, contexto y dificultad de despliegue. Es por ello por lo que, en esta práctica, empleando los conocimientos adquiridos en las clases teóricas, se explorará más en profundidad EC2 y todas sus funcionalidades.

Objetivos

El objetivo de esta práctica es explorar y experimentar con las herramientas de balanceo de carga y escalado explicadas en la clase teórica.

Desarrollo de la práctica

1. Despliega dos instancias en EC2 con un servidor web que muestre una página similar pero que se pueda reconocer que es un servidor distinto. E.g. [El servidor de Gabriel 1] [El servidor de Gabriel 2]. Estos servidores deben poder ser accedidos con un navegador desde fuera



Figura 1: Resumen de la instancia 1



Figura 2: Par de claves para la instancia 1

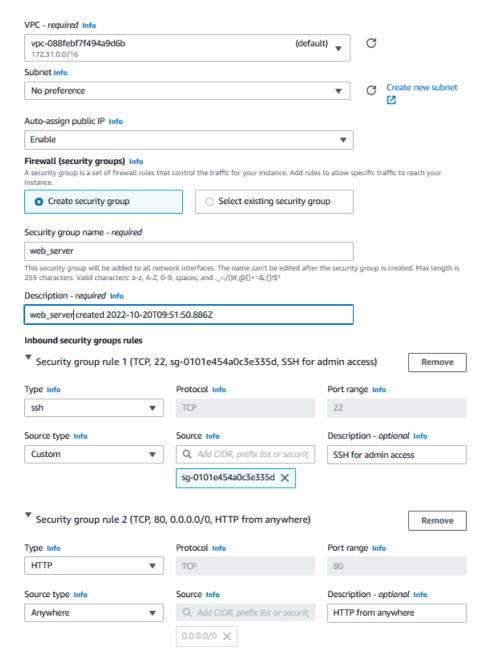


Figura 3: Grupo de seguridad para la instancia 1

Para desplegar las instancias requeridas, se mantendrá la instancia SSH_Gate de la práctica anterior, la cual servirá de acceso mediante SSH a las instancias que se desplegarán a continuación. Para crear la instancia 1, se realiza el mismo proceso de anteriores prácticas. Para ello, a partir de la opción *Launch Instantes* de Amazon EC2, introducimos de nombre de instancia "web_server_1_p2", y se selecciona Amazon Linux como imagen y t2.micro como tipo de instancia en su versión *Free Tier*.

Para configurar el grupo de seguridad de la máquina, estableceremos reglas para permitir solo el acceso SSH a la instancia SSH_Gate, y las solicitudes HTTP desde cualquier lado a la máquina, restringiendo cualquier otra conexión.

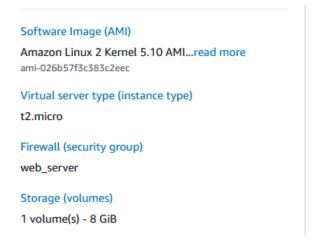


Figura 4: Resumen de la instancia 2

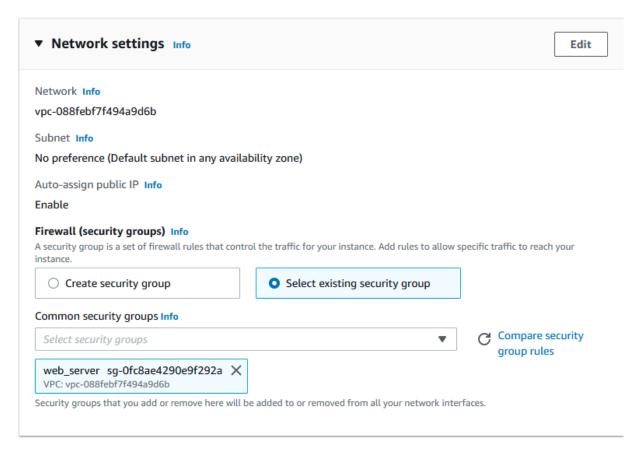


Figura 5: Grupo de seguridad para la instancia 2

Para la instancia 2, se genera del mismo modo que la instancia 1 pero de forma más simple. Esto es debido a que, aunque se genera una nueva imagen y un nuevo par de claves, el grupo de seguridad será el mismo que el de la instancia 1, pues al final ambas máquinas tienen la misma función, es decir, actuar como servidor web, y ambas serán accedidas desde la instancia SSH_gate.

```
[ec2-user@ip-172-31-27-246 .ssh]$ touch web_server_1_p2.pem
[ec2-user@ip-172-31-27-246 .ssh]$ touch web_server_2_p2.pem
[ec2-user@ip-172-31-27-246 .ssh]$ sudo vim web_server_1_p2.pem
[ec2-user@ip-172-31-27-246 .ssh]$ sudo vim web_server_2_p2.pem
[ec2-user@ip-172-31-27-246 .ssh]$ ls
authorized_keys known_hosts web_server_1_p2.pem web_server_2_p2.pem
[ec2-user@ip-172-31-27-246 .ssh]$
```

Figura 6: Configuración para el acceso SSH

```
[ec2-user@ip-172-31-93-85 html]$ history
   1 sudo yum update
     yum -y install httpd
   3 sudo yum -y install httpd
   4 sudo systemctl enable httpd
   5 sudo vim /var/www/http/index.html
   6 cd /var
     ls
     cd www
     ls
  10 cd html/
  11 ls
  12 touch index.html
  13 sudo touch index.html
  14 sudo vim index.html
     systemctl start httpd
     sudo systemctl start httpd
```

Figura 7: Configuración del servicio Apache/HTTP

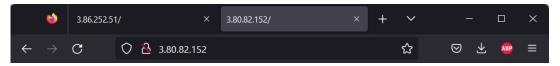
Una vez se han lanzado las dos instancias, podemos acceder a ellas a través de la instancia SSH_Gate para instalar el servicio Apache y configurar el servidor web en ambas. Para ello, se ejecuta el conjunto de órdenes apreciable en la **Figura 7**: Configuración del servicio Apache/HTTP, donde en ambas instancias logra instalar y arrancar el servicio.

Ya configurado, se necesita poder mostrar algo cuando accedamos a cada servidor además de poder diferenciarlos. Es por ello por lo que se modifica el index.html de cada servidor para que en uno de ellos muestre "El servidor de Raúl: 1", y en el otro el "El servidor de Raúl 2", como se logra ver accediendo a cada servidor desde sus direcciones IP públicas facilitadas por AWS.

Para poder acceder a ambos desde navegadores externos, se configuró, mencionado previamente, el grupo de seguridad al que pertenecen estas dos instancias para solo permitir el acceso SSH desde SSH_gate y peticiones HTTP por el puesto 80.



Figura 8: Servidor 1 en activo



El servidor de Raúl: 2

Figura 9: Servidor 2 en activo

2. Despliega un "load balancer" que distribuya las peticiones entre los dos servidores a partes iguales

En esta parte de la práctica, se desplegará un *load balancer* que gestionará la carga de las instancias asociadas a él para repartir las peticiones a partes iguales. Para crearlo, se accede al apartado de *"load balancers"* dentro de EC2 para crearlo.

En la configuración básica, se le asigna un nombre identificativo como es "web_server_load_balancer", así como se identifica el esquema del *load balancer* como Internet-facing, ya que enrutará las peticiones de los clientes por internet a las instancias objetivo. Por último, se seleccionan las IP de tipo IPv4, recomendadas para este tipo de balanceo de carga.

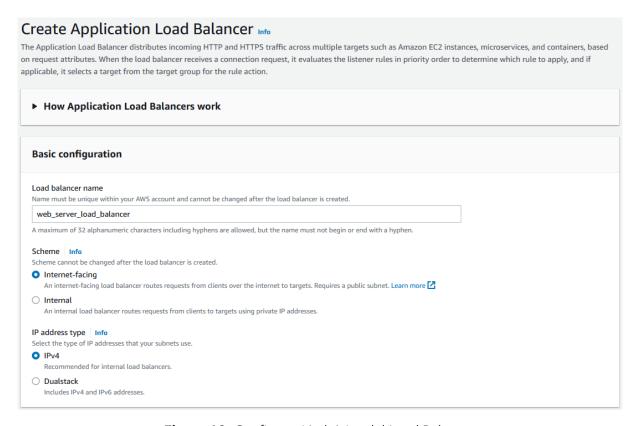


Figura 10: Configuración básica del Load Balancer

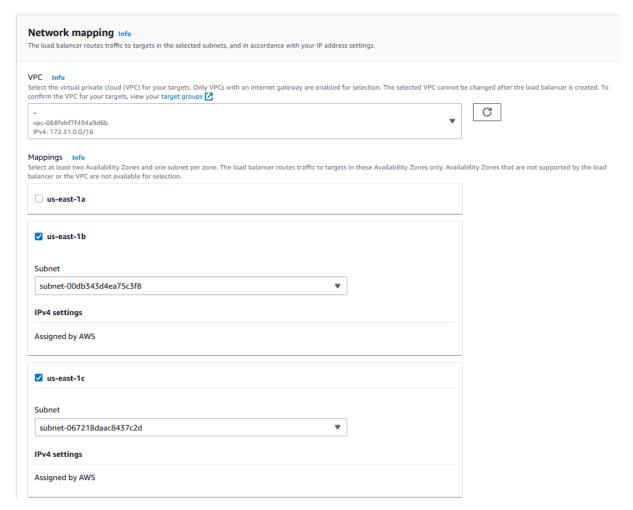


Figura 11: Mapeo de red

Como el load balancer enruta el tráfico a las instancias en las subredes seleccionadas, debemos elegirlas acorde con las instancias ya creadas. Por ello, en este caso, se eligen las subredes visibles en la **Figura 11:** Mapeo de red

Por otro lado, se debe asignar un grupo de seguridad al *load balancer*, por lo cual, aplicaremos el mismo que a las dos instancias creadas ya que el fin sigue siendo que solo se acepten peticiones HTTP desde el exterior.



Figura 12: Grupo de seguridad del load balancer

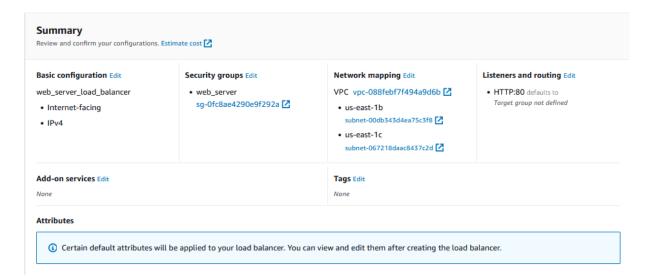


Figura 13: Resumen del load balancer

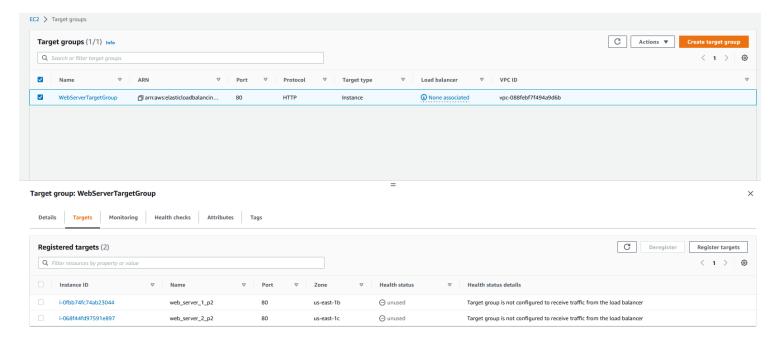


Figura 14: Target group del load balancer

Como era de esperar, de nada sirve un load balancer si no asignamos un grupo de instancias las cuales debe gestionar su tráfico. En EC2, esto se llama *Target Group*, el cual se debe configurar para incluir en él las instancias que necesitemos y asociarlo al *load balancer*.

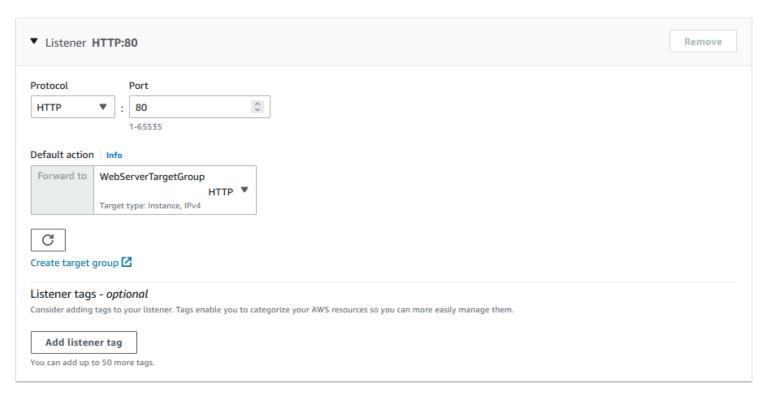


Figura 15: Escucha por el puerto 80

Por último, se especifica que cualquier petición que llegue por el puerto 80, debe ser tratada por el Load Balancer, haciendo uso del Target Group creado para saber a qué instancia debe enrutar la petición. Una vez creado, podremos acceder al panel de control del mismo y acceder a su nombre en el DNS.

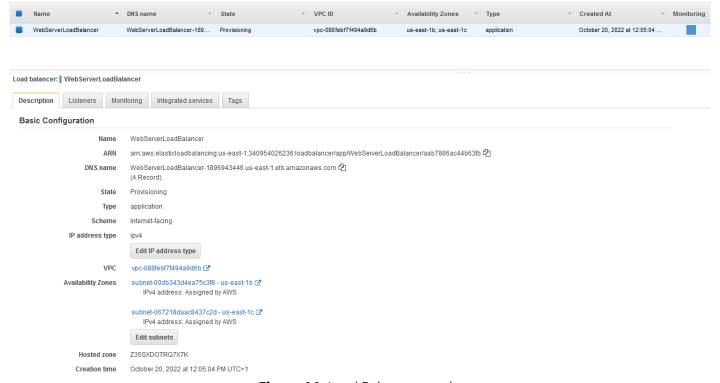
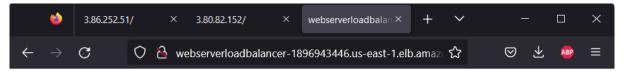
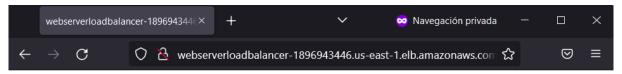


Figura 16: Load Balancer creado



El servidor de Raúl: 2

Figura 17: Prueba de funcionamiento del load balancer 1



El servidor de Raúl: 1

Figura 18: Prueba de funcionamiento del load balancer 2

Para probar el funcionamiento del load balancer una vez este esté desplegado, no hay más que llevar su *DNS name* al navegador y actualizar la página algunas veces, para ver como unas veces nos mostrará el servidor 1 y otras el servidor 2, lo que nos dice que el balanceo de carga está funcionando correctamente.

3. Prepara un "template" de instancia para EC2 para generar servidores web. Con el "template" declarar un "Auto-Scaling Group"(ASG) que tenga como mínimo una instancia y como máximo 2. El ASG debe añadirse al "load balancer" previamente desplegado. Comprueba que el ASG mantiene al menos una instancia viva y que el "load balancer" le manda peticiones entrantes

Para generar servidores web sin tener que estar constantemente creando y configurando instancias, podemos generar un "template" que lo haga por nosotros. Para ello, desde el apartado Launch template, podemos comenzar a desarrollar nuestra plantilla.

En primer lugar, como configuración básica, se le dará un nombre y una descripción, tal y como se ve en la **Figura 19:** Configuración básica del template.

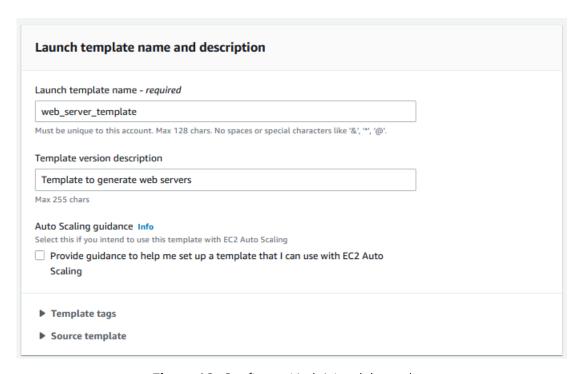


Figura 19: Configuración básica del template

En consecuencia, crear un template es prácticamente idéntico que crear una instancia, por lo que deberemos asignar una imagen, en este caso, Amazon Linux, así como el tipo de instancia (t2.micro en su versión *free tier*), un par de claves y un grupo de seguridad, el cual emplearemos el mismo que hemos empleado tanto para instancias anteriores como para el Load balancer, pues es justo lo que necesitamos para permitir peticiones por el puerto 80 al servidor web.

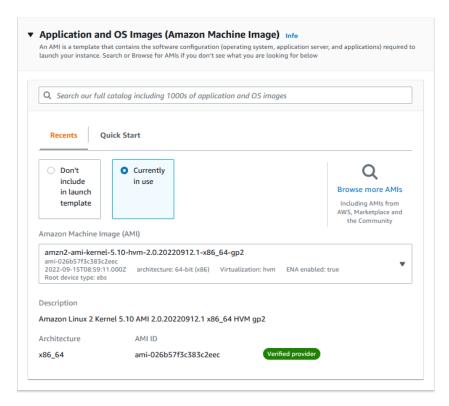


Figura 20: Amazon Linux como imagen de las instancias creadas por el template

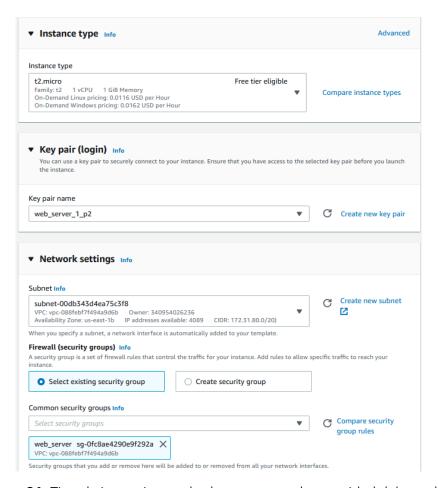


Figura 21: Tipo de instancia, par de claves y grupo de seguridad del template

En lo que si cambia la creación de este template de las instancias que hemos generado anteriormente, es que para no estar instalando y configurando siempre el servidor web, en el apartado User data justo al final en opciones avanzadas, introducimos el pequeño script apreciable en la **Figura 22**: Script para instalar y configurar el servidor web.

En él, se realizan todas las actualizaciones pertinentes para a continuación instalar e iniciar el servicio Apache, así como conceder los permisos necesarios y configurar la página principal del servidor para diferenciarlo de las demás instancias.

```
#!/bin/bash
yum update -y
yum install -y httpd
systemctl enable httpd
systemctl start httpd
usermod -a -G apache ec2-user
chown -R ec2-user:apache /var/www
chmod 2775 /var/www
find /var/www -type d -exec chmod 2775 {} \;
find /var/www -type f -exec chmod 0664 {} \;
echo '<html><h1>El servidor de Raúl: 3</h1><h2>Generado por un template</h2>
</html>' > /var/www/html/index.html
```

Figura 22: Script para instalar y configurar el servidor web

Una vez creado el *template*, podemos desplegar un *Auto-Scaling Group*, el cual deberá tener siempre al menos una instancia viva generada por el *template* y que el *load balancer* le reenvíe peticiones entrantes. Para crearlo, como en cualquier cosa, nos solicita un nombre y el template que queremos emplear para generar instancias.

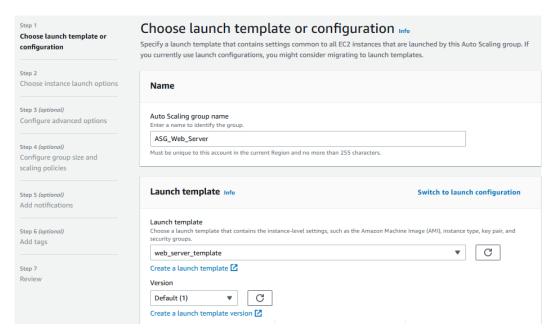


Figura 23: Creación del ASG

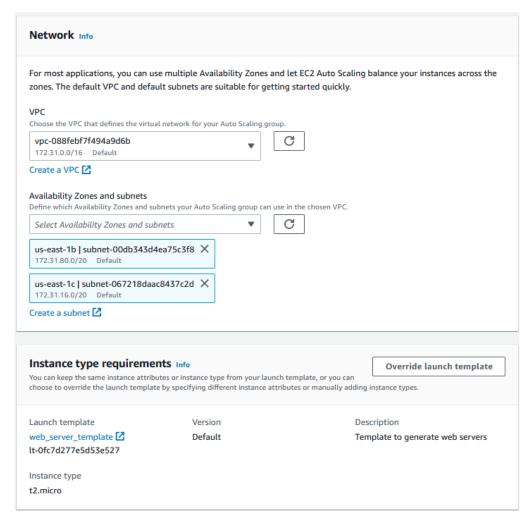


Figura 24: Configuración de Red

Para la configuración de red, debemos elegir las zonas disponibles y subredes en las cuales el ASG puede generar nuevas instancias. Tratando por anticipado de evitar problemas con el *load balancer*, seleccionamos las mismas subredes que este.

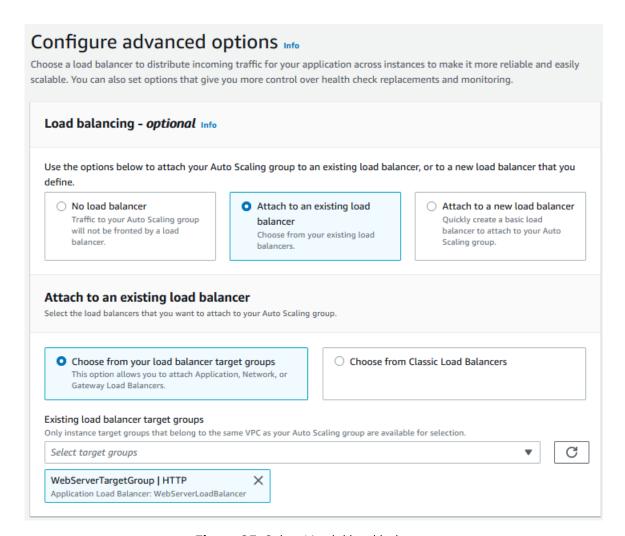


Figura 25: Selección del load balancer

En la propia configuración del ASG permite asociarlo con un *load balancer* ya existente, por lo que en este caso se asocia ya con el que creamos anteriormente y se selecciona el *Target Group* creado para que, cualquier instancia creada por el ASG, se incluya en este y el load balancer pueda redirigirle peticiones entrantes.

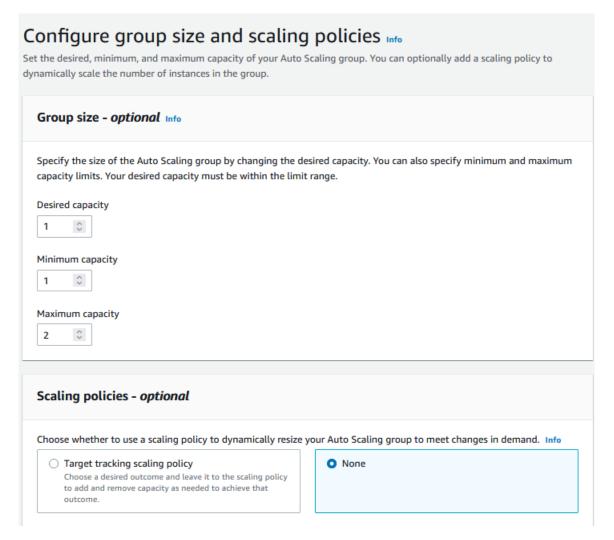


Figura 26: Tamaño del ASG

Para que al menos siempre exista una instancia viva, en la capacidad deseada se debe seleccionar 1, y se establece el mínimo y máximo de instancias en 1 y 2 respectivamente, para cumplir con las especificaciones de la práctica. Con esto se finalizaría la configuración del ASG y solo se deberá esperar a que esté en funcionamiento para ver si el *load balancer* envía peticiones a las instancias creadas por el ASG.

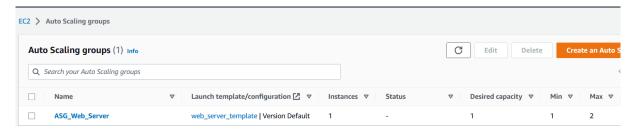
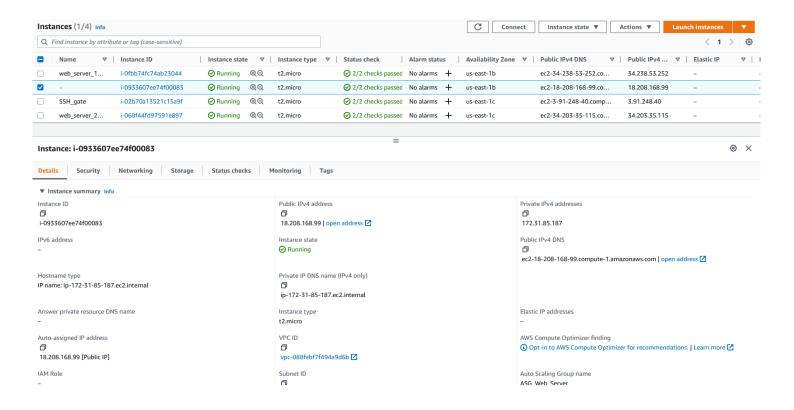
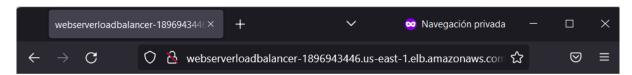


Figura 27: ASG creado



Una vez inicializado, se crea automáticamente una instancia. Es por ello, que al acceder al DNS name del load balancer desde un navegador, si enviamos varias peticiones debería en alguna respondernos esta nueva instancia, como se aprecia en la **Figura 28**: ASG integrado correctamente en el Load Balancer.

De esta manera, finaliza el desarrollo de la práctica.



El servidor de Raúl: 3

Generado por un template

Figura 28: ASG integrado correctamente en el Load Balancer

Diagrama de arquitectura desplegada

Web Server 1 Web Server 2 Web Server 2 Web Server 3 Web Server 3 Web Server 1 Web Server 1 Web Server 1 Web Server 1

La arquitectura desplegada corresponde a un *load balancer* que distribuye las peticiones HTTP a partes iguales entre las instancias que formen parte del Target Group asociado al *Load Balancer*.

Por una parte, tenemos las dos instancias del apartado 1, las cuales son accedidas mediante la instancia SSH_gate, creada en la anterior práctica. Por otra parte, el ASG creado se asocia con el load balancer para que las instancias que cree, ya configuradas como servidores web, se incluyan en el target group y puedan recibir peticiones entrantes por el puerto 80.

Presupuesto y estimación de gasto de los recursos desplegados

Entendiendo el presupuesto como el dinero que tenemos para montar y desarrollar esta práctica, se puede decir que este es del 100\$. Ahora bien, siendo realistas, durante el transcurso de la asignatura se realizarán 8 prácticas, donde la práctica 1 se estimó su gasto en aproximadamente 1\$, por lo que tendríamos 99\$ a repartir entre 7 prácticas restantes, siendo 14,14\$ de presupuesto para cada práctica.

Para la estimación de gasto, hay que tener en cuenta sobre todo el precio de un *Elastic Load Balancer*, en su versión *Application Load Balancer*. Por hora, nos encontramos con un precio de 0.0225\$, mientras que por cada instancia en ejecución el precio será de 0.0116\$ cada una por hora. Además, el uso de volúmenes SSD de uso general (gp2) cuesta 0,10\$ por GB-mes¹.

Es por todo ello que, teniendo en cuenta que el desarrollo normal de la práctica debería durar unas dos semanas aproximadamente, aunque puede ser menos o más, y que el load balancer siempre está activo dando el servicio al exterior, la estimación de gasto en esta práctica quedaría tal que:

$$(0.0225 + 3 * (0.0116)) * 336 horas + 0.10 * 14 días = 20.65$$
\$

Nuestra estimación de gasto máximo será de 20.65\$, en un caso en el que tanto el *load* balancer como las instancias estén las 24 horas del día, durante dos semanas, siempre en ejecución. Estimando que, para completar la práctica en dos semanas, cada día estén activas como mucho 1 hora, la estimación de gastos quedaría tal que:

$$0.0225 * 336 \ horas + (3 * 0.0116) * 14 \ horas + 0.10 * 14 \ días = 7.56 + 0.4872 + 1.4 = 9.4472$$
\$

Ya en el caso más realista, la práctica se ha completado en menos de una semana, por lo que, aproximando justamente 7 días para su desarrollo, la estimación más precisa sería de **4,72\$**, justo la mitad.

En casos reales donde el *load balancer* debiera estar siempre dando servicio, mensualmente saldría a 0.0225 * 744 = 16,74\$, sin contar cuantas instancias están asignadas a su *target group* ni el precio de los volúmenes de esas instancias, pero es evidente que saldría mucho más cara que cualquiera de las estimaciones desarrolladas.

¹ https://aws.amazon.com/es/premiumsupport/knowledge-center/ebs-volume-charges/

Conclusiones

Una vez concluida la práctica, se ha adquirido el conocimiento necesario para desplegar un balanceador de carga con vistas a dar servicios públicos, en este caso, un servidor web que puede recibir peticiones en cualquier instancia del *load balancer*.

Otro de los puntos clave aprendidos es el uso del "template" y como puede ser de gran utilidad y eficacia a la hora de generar nuevas instancias a partir de un modelo, ahorrando al encargado el tener que configurar el servicio a prestar y realizar un mantenimiento.

En definitiva, se han visto herramientas enfocadas en dar servicios al exterior, combinando los fundamentos antiguos con las nuevas tecnologías y creando infraestructuras nunca vistas y más fáciles de crear que nunca.